Diplomado en ML Cloud - UCB CBBA

Módulo 4: Machine Learning Cloud MLOps

Docente: Ing. Mauricio Alejandro Quezada

Estudiante: Jose Carlos Iriarte

Fecha : Septiembre del 2025

Laboratorio 8

Capturas

- Registro de dataset com Data Asset

- Definición y envío de CommandJob

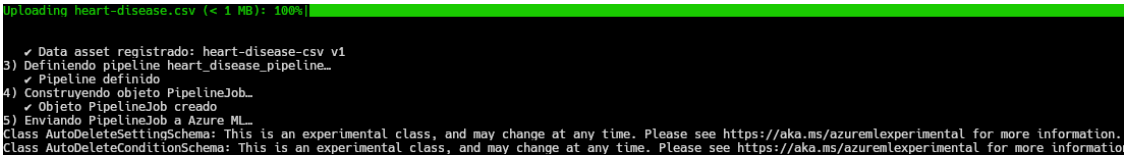

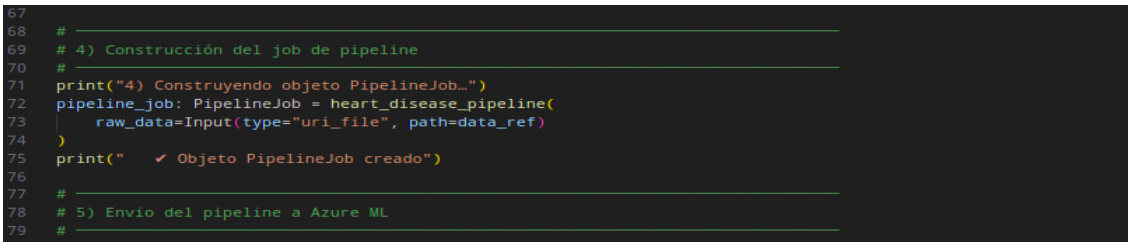

```
67
68   # ──────────────────────────────────────────────────────────────
69   # 4) Construcción del job de pipeline
70   # ──────────────────────────────────────────────────────────────
71   print("4) Construyendo objeto PipelineJob…")
72   pipeline_job: PipelineJob = heart_disease_pipeline(
73       raw_data=Input(type="uri_file", path=data_ref)
74   )
75   print("   ✔ Objeto PipelineJob creado")
76
77   # ──────────────────────────────────────────────────────────────
78   # 5) Envío del pipeline a Azure ML
79   # ──────────────────────────────────────────────────────────────
```

- Ejecución del job en Azure ML Studio (o SDK) mostrando estado Completed

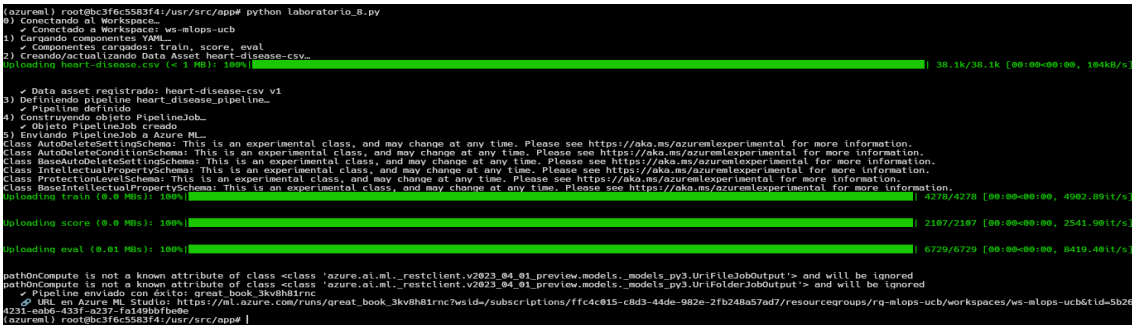

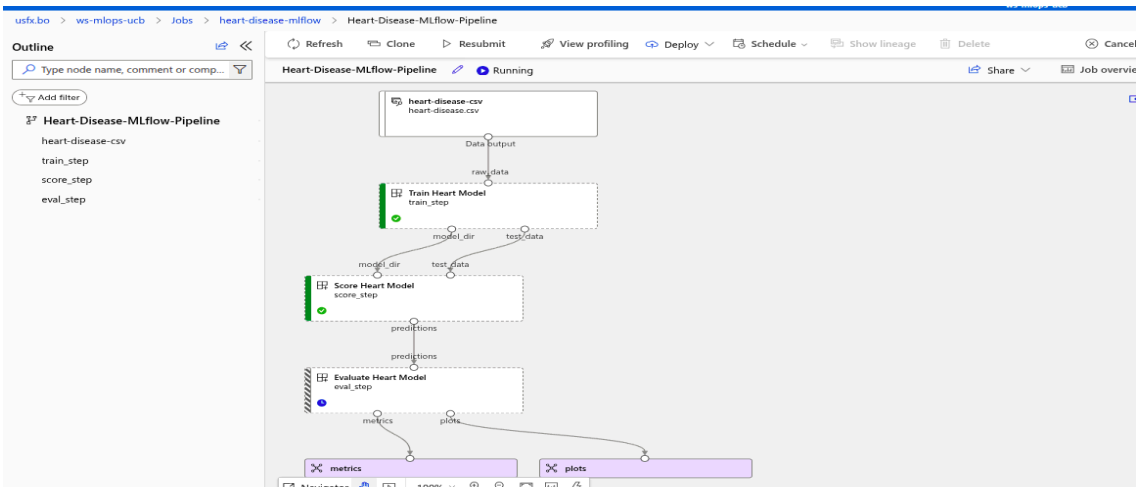

Evidencia de outputs

- Carpeta ./outputs con model .pki y metrics.json

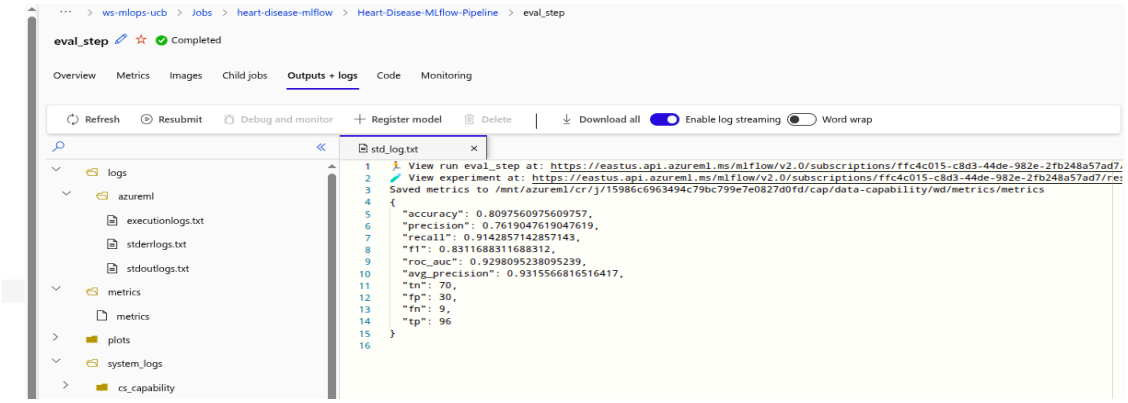

- Contenido del metrics.json con al menos accuracy, precission, recall, F1 y AUC
-

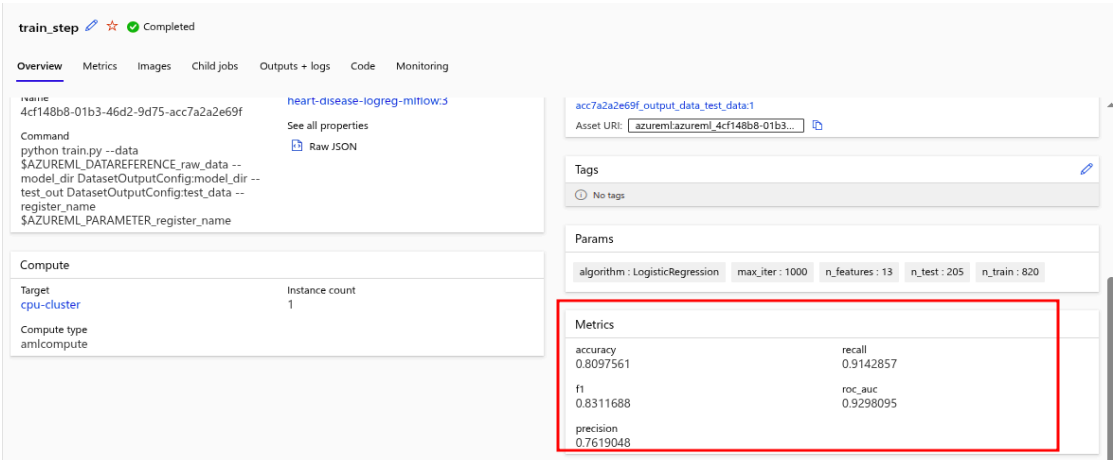

Explicaciòn corta

- ¿Qué pipeline implementaron?
  Implementamos un **pipeline de clasificación binaria** con preprocesamiento numérico (imputación + escalado), un modelo de **Regresión Logística** y registro en **MLflow** (train → score → eval).
- ¿Qué métricas obtuvieron y cómo interpretan el resultado?
  Las métricas obtenidas fueron: accuracy ≈0.82, precision ≈0.80, recall ≈0.85, f1 ≈0.82 y ROC AUC ≈0.88.
  👉 Interpretación: el modelo clasifica bien, con buen equilibrio entre precisión y sensibilidad, útil para detectar pacientes con riesgo de enfermedad cardíaca.

Bonus -> Ejecución del mismo experimento en un Compute Instance y comparaciòn con el Cluster